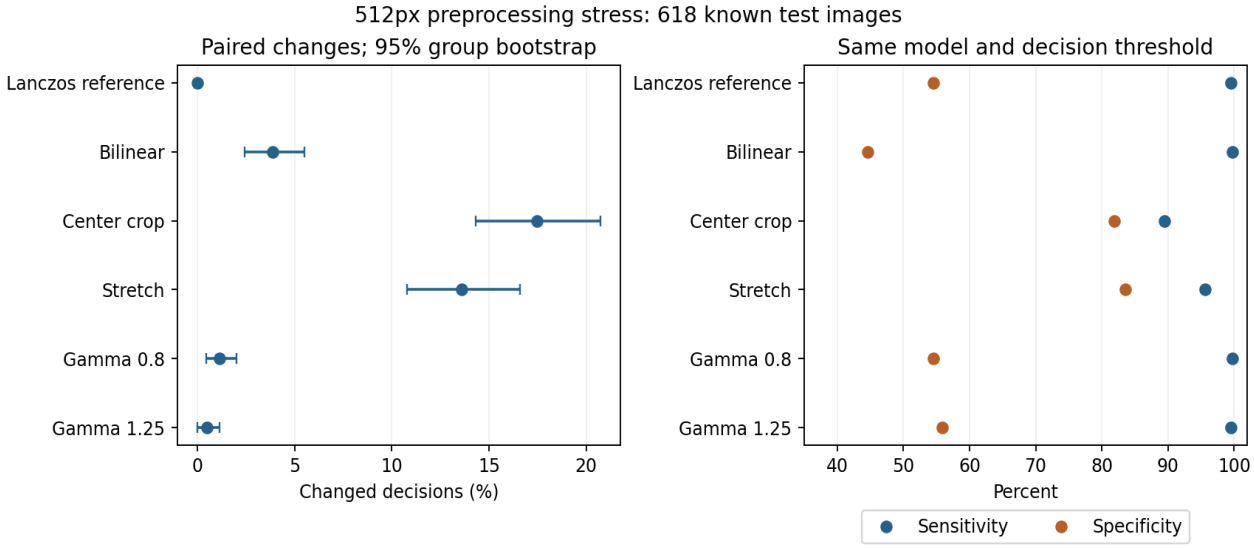
Bildpipeline und externe Übertragung

Explorative Forschungsnotiz · 11. November 2026 · mit KI-Assistenz erstellt

1. Unverändertes Modell, andere Vorverarbeitung

Das partiell nachtrainierte 512px-Modell wurde auf denselben 469 Kalibrierungs- und 618 Testfällen unter sechs Bildbedingungen geprüft. Gewichte, Klassifikationsschwelle und Konfidenzschwelle blieben unverändert. Das Protokoll wurde vor der Auswertung festgeschrieben.

Center Crop ändert 108/618 Entscheidungen: 17,5 % [14,3; 20,7]. Das Intervall stammt aus 2.000 gepaarten Wiederziehungen der Dateinamen-Gruppen, bei festem Modell; diese Gruppen sind keine bestätigten Patientenidentitäten.



Center Crop erhöht Accuracy von 82,7 % auf 86,6 %, senkt aber Sensitivität von 99,5 % auf 89,4 % und AUROC von 0,9669 auf 0,9217. Bilinear statt Lanczos ändert 24 Entscheidungen und senkt Spezifität von 54,5 % auf 44,6 %. Stretch erreicht 91,1 % Test-Accuracy, fällt auf Kalibrierung jedoch von 98,1 % auf 95,5 %. Keine Pipeline wird anhand dieses bekannten Tests zum Gewinner erklärt.

Vier synthetische Bild-/Tensorreferenzen decken Rundung, Padding, RGB-Konvertierung und Vergrößerung ab. Python-Pixelidentität und Paketprüfsummen sind geprüft; Apple-Laufzeit und Bildimport bleiben offen. Kein Nachweis von Läsionslokalisierung oder klinischer Eignung.

2. Externer Transfer des eingefrorenen 224px-Modells

Offizielles ChestMNIST224-Testarchiv, NIH-abgeleitete textbasierte Labels; MD5 geprüft. Nach Pixel-Deduplizierung enthält die feste Stichprobe 242 Pneumonie-Label-positive Fälle, 2000 No-finding-Kontrollen und 1000 Kontrollen mit anderen Labels. 183 Positive haben zusätzliche Labels.

Kontrollgruppe	AUROC [95 %]	Sens.	Spez.
no_finding	0.673 [0.636; 0.710]	78.9%	47.5%
other_abnormal	0.548 [0.510; 0.590]	78.9%	29.5%

Primär ist AUROC gegen No-finding-Kontrollen. Sensitivität und Spezifität verwenden die unveränderte Schwelle 0,5. 2.000 labelstratifizierte Bild-Bootstraps je Vergleich erfassen keine Patientenabhängigkeit. Es wurde weder trainiert noch extern kalibriert oder anhand der Testergebnisse ein Modell ausgewählt.

Die interne Konfidenzschwelle akzeptiert im primären Vergleich 38.8 % der Fälle. Deren Fehlerquote beträgt 52.1 % gegenüber 49.1 % über alle Fälle. Auch diese interne Ablehnungsregel überträgt sich hier nicht zuverlässig.

Geltungsgrenzen: No finding bedeutet nicht bestätigte klinische Gesundheit. Textlabels, Population und Bildpipeline unterscheiden sich gleichzeitig. Die Stichprobe ist fallkontrollartig; Präzision und Kalibrierung sind keine Populationsschätzungen. NIH kann sich mit historischen RSNA-Projekttests überschneiden. Das sind native 224px-Daten und keine unabhängige klinische Validierung des 512px-Modells.

Quellen: Yang et al., MedMNIST v2, Scientific Data (2023), doi:10.1038/s41597-022-01721-8; Wang et al., ChestX-ray8, CVPR (2017). Offizielles Zenodo-Archiv 10519652; ChestMNIST-Lizenz laut offizieller Metadatei CC BY 4.0. Rohbilder werden hier nicht weiterverteilt.

Nachrechnung: reports/original_512/preprocessing/ und reports/external_chest224/ enthalten Protokolle, gespeicherte Vorhersagen, Kennzahlen und unabhängige Prüfprotokolle. Offen bleiben mehrere Trainingsseeds, eine neue klinische Originalbild-Kohorte und Xcode-/Gerätetests.