Originalbilder und 512px: neuer Ausgangsvergleich

Medical AI Reliability Lab · 11. November 2026 · Explorative Forschungsnotiz

Fünf Modelle auf derselben bereinigten Originalbild-Kohorte. Zwei Auflösungen, partielles Nachtraining und größere Encoder werden als getrennte Vergleiche untersucht. Modellwahl und Kalibrierung sind vom Test getrennt; keine Variante wird aufgrund des Testergebnisses nachtrainiert.

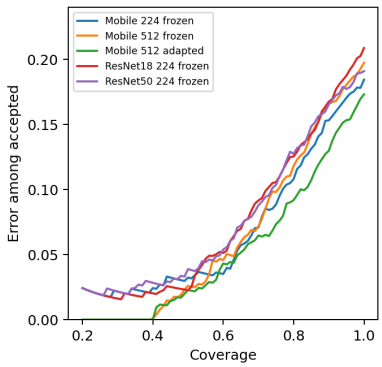
Modell	AUROC	Accuracy	Fehler bei 80 %
Mobile 224, eingefroren	0.9570	81.6%	10.8%
Mobile 512, eingefroren	0.9665	80.3%	11.8%
ResNet18 224	0.9528	79.1%	12.5%
Mobile 512, angepasst	0.9669	82.7%	9.2%
ResNet50 224	0.9487	80.9%	12.7%

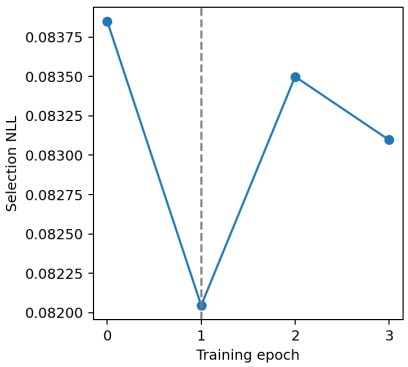
Primär: Mobile 512 minus 224: AUROC-Differenz +0.0096, 95%-Gruppenbootstrap [-0.0042; +0.0251].

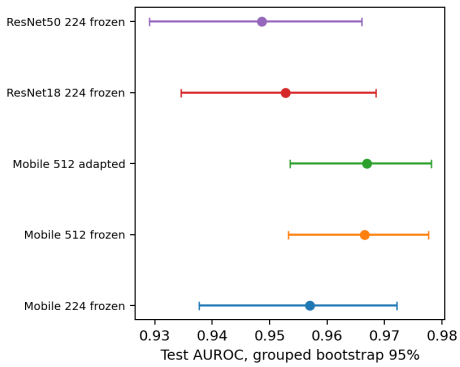
Sekundär: Nachtraining minus eingefroren bei 512: AUROC-Differenz +0.0004, 95%-Gruppenbootstrap [-0.0008; +0.0015].

Sekundär: ResNet50 minus ResNet18: AUROC-Differenz -0.0041, 95%-Gruppenbootstrap [-0.0173; +0.0077].

Nachtraining senkt den Fehler bei 80 % Abdeckung von 11,8 auf 9,2 %. Gegen eine zusätzliche Kontrolle mit demselben Optimierer, bei der nur der Kopf lernt, beträgt der Unterschied -2.43 Prozentpunkte [-3.97; -1.03]. Die AUROC verändert sich kaum; bessere Entscheidungsergebnisse sind nicht dasselbe wie bessere Rangordnung.







Die Intervalle beruhen auf 2.000 gemeinsamen Wiederziehungen von Dateinamen-Gruppen bei fest ausgewählten Modellen. Sie enthalten weder Trainingsseed-Streuung noch Modellwahlunsicherheit. Sekundäre Vergleiche sind nicht für Mehrfachtests korrigiert.

Mehr Bilddetails und sauberere Trennung

Die offiziellen Original-JPEGs stammen aus ChestXRay2017.zip, Kermany, Zhang & Goldbaum (2018), Mendeley Data, DOI 10.17632/rscbjbr9sj.2, CC BY 4.0. Das 1,24-GB-Archiv wurde gegen die veröffentlichte SHA-256-Prüfsumme geprüft. 512px wird aus diesen Originalaufnahmen erzeugt, nicht aus MedMNIST hochskaliert.

Same training image; original 2090 × 1858 px

224px representation, enlarged for display



512px representation from original



Kermany, Zhang & Goldbaum (2018), Mendeley rscbjbr9sj.2 · CC BY 4.0
Modified: grayscale, aspect-preserving resize and black padding.

Teilmenge	Bilder	Positive	Gruppen
train	3842	2754	2153
selection	442	308	268
calibration	469	343	270
test	618	387	426

32 exakte Grauwert-Duplikate wurden entfernt. Weitere 453 Trainingsbilder teilen eine aus dem Dateinamen abgeleitete Kennung mit dem Test und wurden ausgeschlossen. Die Kennungen sind keine unabhängig verifizierten Patientenidentitäten; unbekannte Verknüpfungen und ähnliche Bilder können verbleiben.

Alle 618 Testbilder haben ursprünglich mindestens 728 Pixel an der langen Kante. Die Bilder werden unter Erhalt des Seitenverhältnisses verkleinert und schwarz gepolstert. 55 Nicht-Testbilder besitzen ursprünglich selbst an der langen Kante weniger als 512 Pixel. Auch die höhere Auflösung bleibt meist unter der Originalgröße.

Dies ist dieselbe Quellfamilie wie MedMNIST. Neue Bereinigung, Aufteilung und Vorverarbeitung verhindern einen direkten Vergleich der absoluten Zahlen mit früheren Studien. Kein neuer externer Standort, keine klinische Einsatzprüfung.

Training, Klassenfehler und SwiftUI-Pfad

MobileNetV3-Small: 927,585 Parameter mit neuem Kopf. ResNet-50: 23,510,081. Die eingefrorenen Encoder erhalten neu trainierte lineare Köpfe; C wird nur auf Modellwahl-NLL gewählt. Beim 512px-MobileNet werden zusätzlich die letzten Encoderblöcke angepasst. Gewählte Epoche: 1 von 0–3; Epoche 0 ist die unveränderte Referenz. BatchNorm und der frühe Encoder bleiben fest.

Modell	Sensitivität	Spezifität
Mobile 224, eingefroren	99.7%	51.1%
Mobile 512, eingefroren	99.7%	47.6%
ResNet18 224	99.2%	45.5%
Mobile 512, angepasst	99.5%	54.5%
ResNet50 224	99.2%	50.2%

Die Klassenschwelle ist 0,5. Beim angepassten 512px-Modell fällt die Spezifität von 98,4 % auf Kalibrierungsbildern auf 54,5 % im Test. Eine nachträgliche diagnostische Schwellenanalyse verschärft den Befund: Ein ausschließlich auf Kalibrierungsfällen gewähltes 95%-Spezifitätsziel erreicht im Test nur 52,4 %. Die Ursache dieser Übertragungslücke ist nicht isoliert; diese Schwellen werden nicht in die App übernommen.

Technischer Weg zur App

Lokaler vollständiger 512px-Checkpoint: 3.84 MB. Core-ML-Konvertierung: erfolgreich. Das Paket nimmt einen Float32-Grauwerttensor mit 512×512 Pixeln entgegen; Normalisierung liegt im Modell. Eine synthetische Referenzeingabe und ein SwiftUI-Tensorprüfer sind vorbereitet.

Nicht durchgeführt: Xcode-Build, numerischer Vergleich auf Apple-Hardware, iOS-Bildvorverarbeitung und Geräte-Latenz. Die Linux-CPU-Messungen lassen sich nicht als iPhone-Geschwindigkeit ausgeben. Der Export ist ein Forschungsschritt, keine fertige Diagnose-App.

Nachprüfbarkeit und Grenzen

Quelle, Ausschlüsse, Protokolle, Modellwahl, Vorhersagen, Gruppenbootstrap, unabhängige Prüfer und Exportvertrag sind unter reports/original_512/ gespeichert. Code und Analysen wurden mit Codex erstellt und ausgeführt. Eine externe fachliche Prüfung wird nicht behauptet. Nächste Evidenzstufe: unabhängige klinische Kohorten, mehrere Trainingsseeds und Robustheit des angepassten Encoders; größere Auflösung oder Architektur allein garantiert keinen Gewinn.