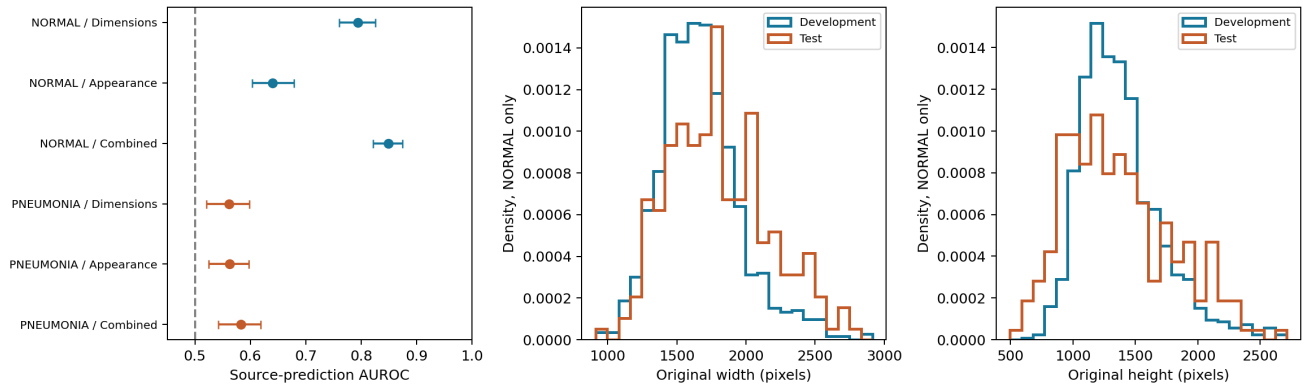
Herkunftslücke bei Original-Thoraxbildern

11. November 2026 · Explorative Nachanalyse · Medical AI Reliability Lab

Das nachtrainierte 512px-Modell erreicht 98,4 % Spezifität auf Kalibrierungsbildern, aber nur 54,5 % im Test. Die neue Analyse prüft, ob sich die Teilbestände innerhalb derselben klinischen Klasse anhand einfacher Bildmerkmale unterscheiden.

Bei NORMAL-Bildern erkennen Breite und Höhe die Herkunft mit AUROC 0,794 [0,760; 0,826]. Mit zusätzlichen Erscheinungsmerkmalen steigt sie auf 0,849 [0,822; 0,875]. Bei PNEUMONIA liegt der kombinierte Wert nur bei 0,583 [0,543; 0,618]. Diese Zahlen messen Herkunft, nicht Krankheitsdiagnose.



Kontrolle gegen triviale Erklärungen: getrennte Auswertung je klinischer Klasse, keine Dateinamen/IDs als Eingaben, fünf Folds mit getrennten Dateinamen-Gruppen und nur im Trainingsfold angepasste Skalierung. Schwarzes Padding wird vor der Helligkeitsanalyse geometrisch entfernt; echte schwarze Bildpixel bleiben erhalten.

Unsicherheit: 2.000 nach Herkunft stratifizierte Gruppen-Wiederziehungen der festen Out-of-fold-Vorhersagen. Die Intervalle erfassen keine vollständige Trainings-/CV-Unsicherheit. Die Nachanalyse wurde durch bekannte Testergebnisse motiviert und ist keine unabhängige Bestätigung.

Bedeutung: Die besonders ausgeprägte Herkunftslücke bei Normalbildern passt zur geringen Testspezifität. Sie belegt keine Ursache der Fehler und keinen bestimmten Shortcut. Die medizinischen Modelle erhalten die ursprüngliche Bildgröße nicht direkt als Zahlenwert. Aufnahmebedingungen, Geometrie, Abtastung und Inhalt können zusammenwirken.

Die bestehenden Modelle und das Core-ML-Paket bleiben unverändert. Für belastbare Verbesserungen stehen eine unabhängig erhobene, repräsentative Kalibrierungs-/Validierungskohorte und gezielte Vorverarbeitungsprüfungen vor weiteren Aussagen über klinische Nutzbarkeit. Vollständige Tabellen, Merkmale, Fold-Modelle und unabhängige Prüfung: reports/original_512/source_audit/.